Manuale Tecnico

Da un pdf a un assistente interattivo.

Hai mai comprato un elettrodomestico e ti sei trovato a sfogliare un manuale enorme:

• cercando la tua lingua,

• leggendo un documento su due colonne con caratteri minuscoli,

• cercando di capire come farlo funzionare? ■

Oppure, peggio ancora, inquadri un **QR code** che ti fa scaricare un PDF sullo smartphone…

e poi scorri disperato alla ricerca delle istruzioni giuste?

Forse ciò di cui abbiamo davvero bisogno è una **RAG**.

RAG => **Retrieval-Augmented Generation**

In pratica, si tratta di:

• convertire il manuale in embeddings (vettori numerici nello spazio semantico)

• indicizzarlo,

=> così da poter cercare rapidamente frammenti utili per rispondere a una domanda specifica.

■ Esempio: “Come installo la base di ricarica del clean robot AXYZD?”

Perché non chiedere a un LLM generico?

Non puoi essere sicuro che la risposta si riferisca al tuo **modello specifico**.

Potresti ricevere **informazioni obsolete o relative a marche concorrenti**.

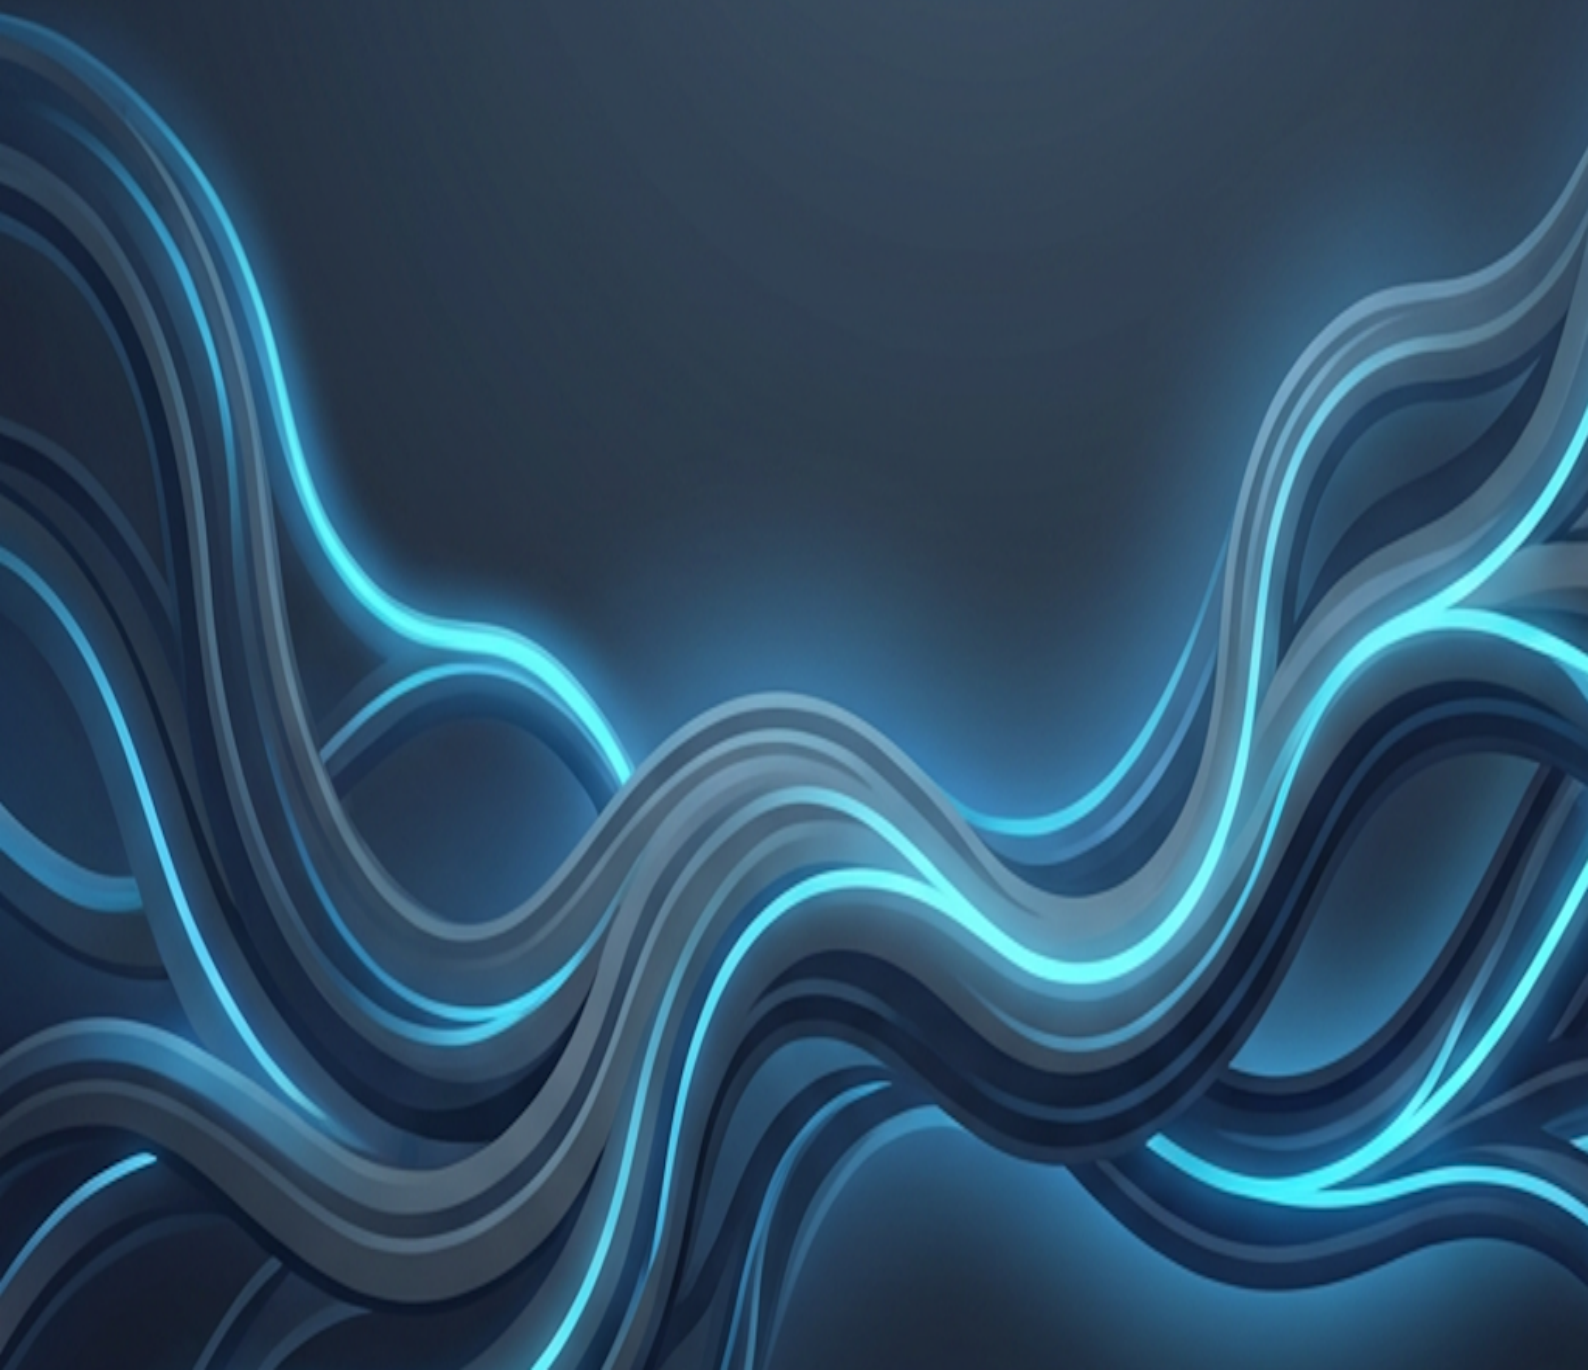

Le **RAG** limitano il campo d’azione dell’LLM, sfruttandone la capacità conversazionale solo sui contenuti ufficiali.

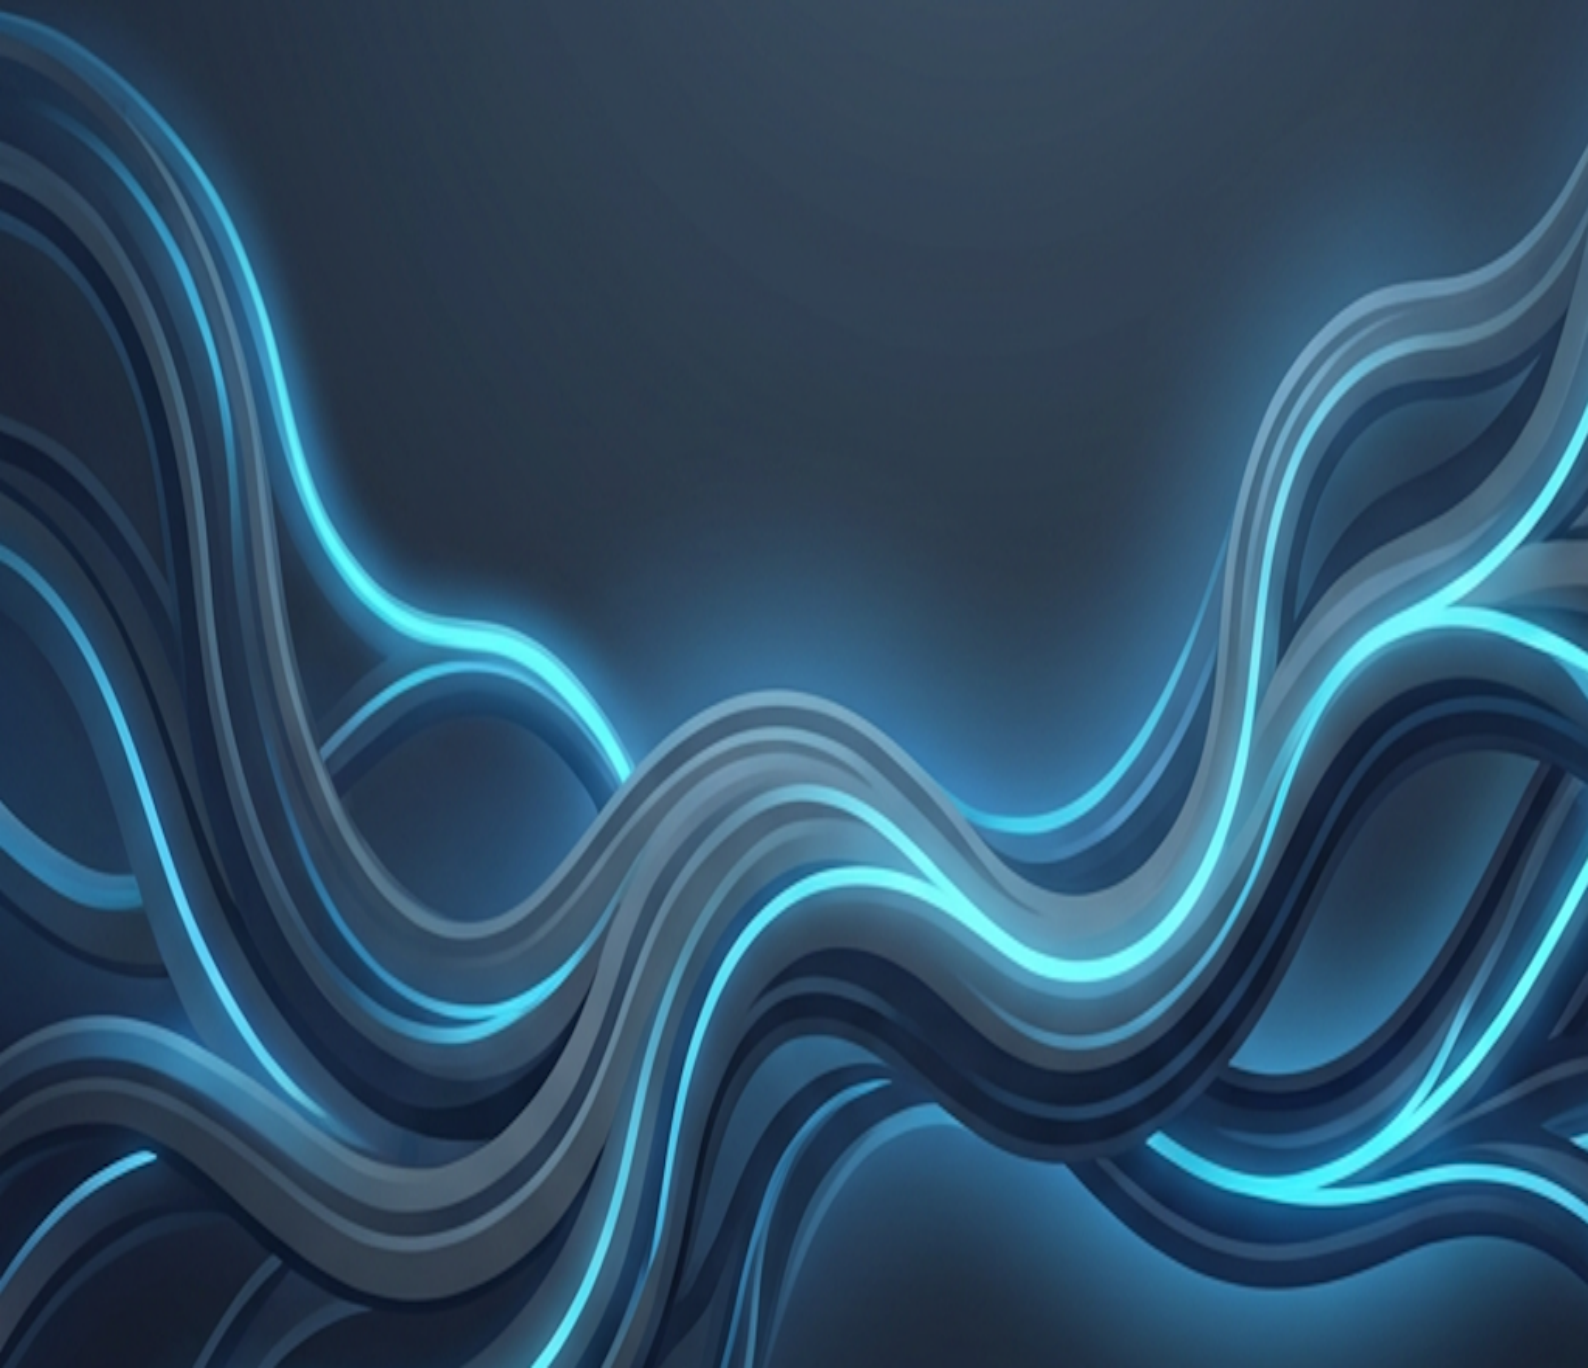

Il processo è semplice, ma potente:

1. L’LLM riceve frammenti specifici del manuale, corredati di foto e didascalie.

2. Risponde alla domanda dell’utente basandosi solo su questi contenuti.

3. Se non ha abbastanza informazioni, ammette di non sapere, evitando risposte vaghe o dannose.

■ Vantaggi concreti delle RAG multimodali:

- Riduzione drastica delle allucinazioni
- Controllo completo sul contenuto fornito
- Aggiornamento facile: basta rigenerare gli embeddings quando il manuale cambia.
- Possibilità di includere immagini come supporto esplicativo

In pratica, il cliente ha un manuale interattivo affidabile, capace di guidarlo passo passo, anche in contesti delicati.

I motori di ricerca fanno qualcosa di simile “on demand”,

cercando contenuti online e componendo la risposta

come un riassunto di quanto trovato,

ma senza garanzie sulle fonti.

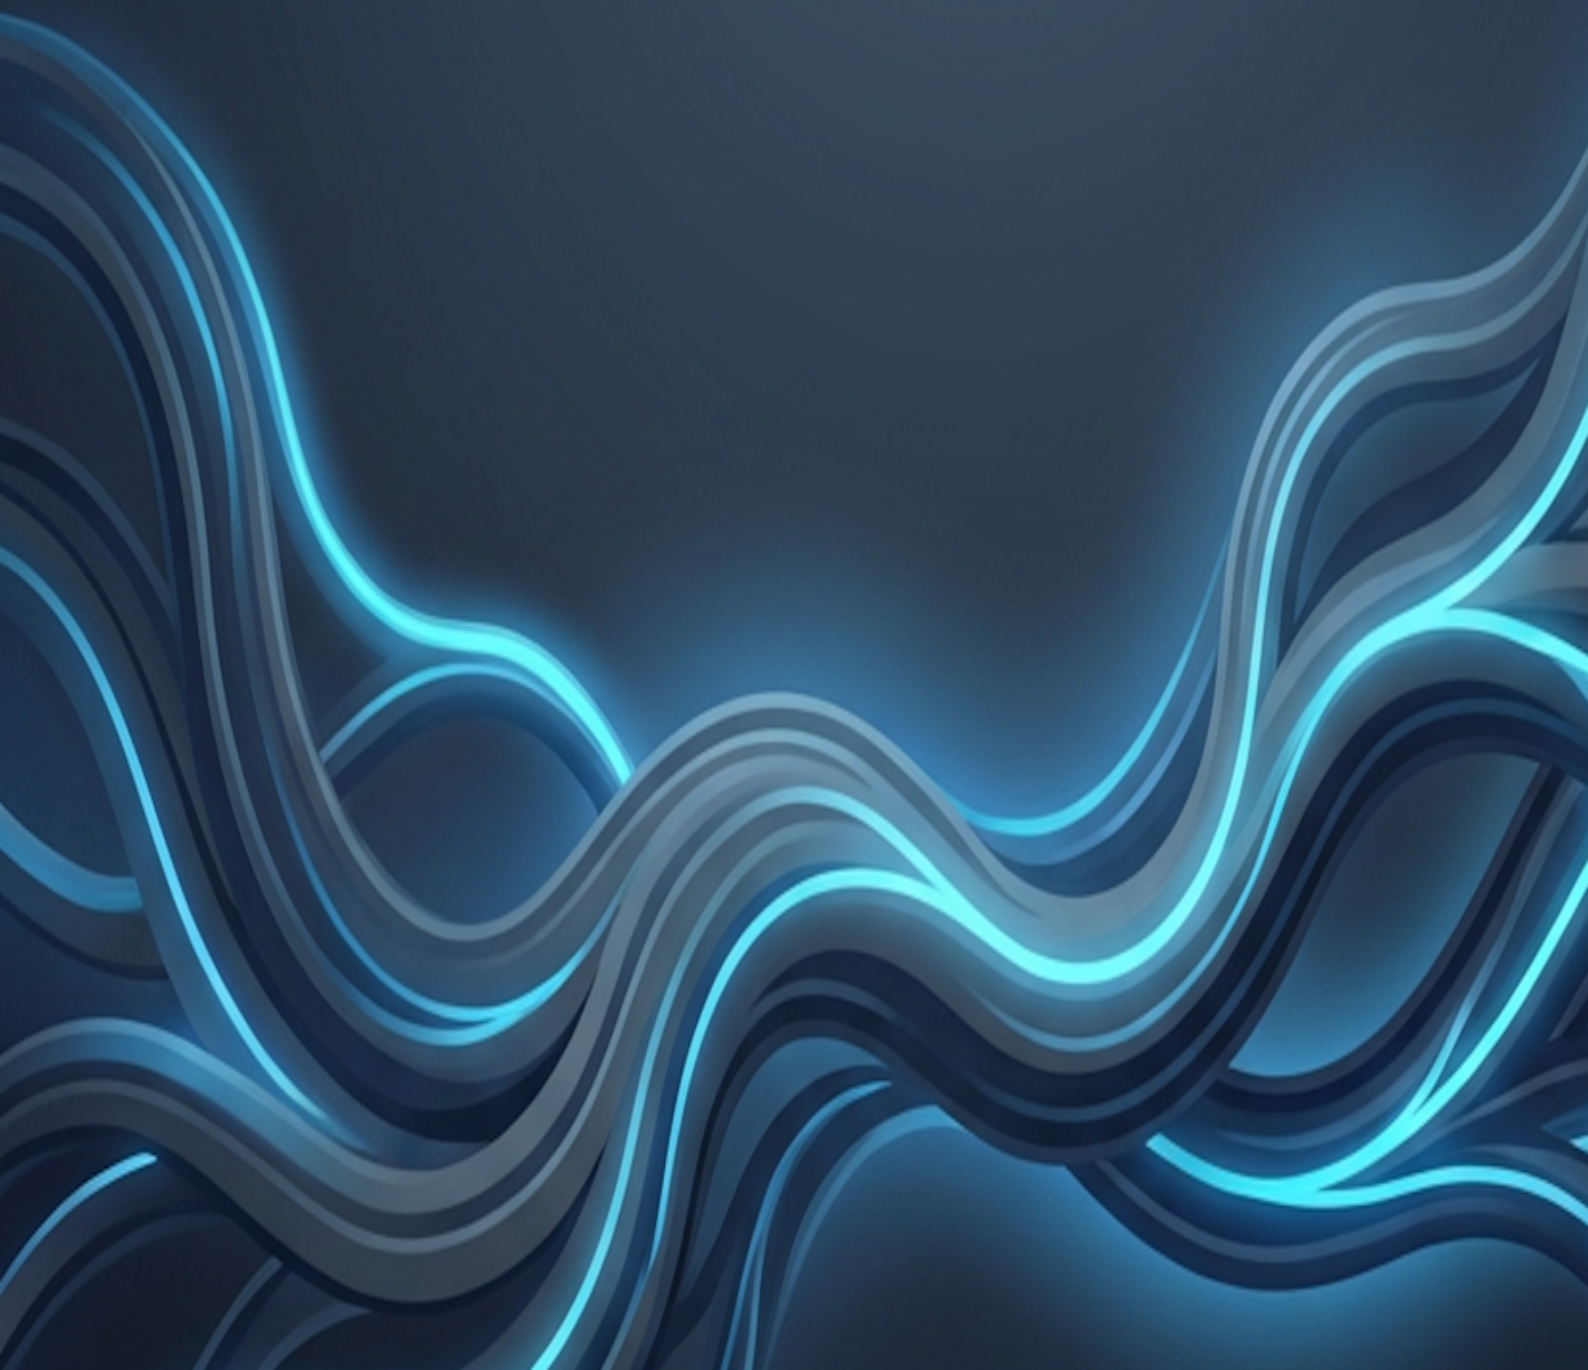

Con una **RAG**, **il controllo è totale**,

le risposte sono affidabili e

l’esperienza utente migliora drasticamente.