Hook

I **Vision Transformer** stanno cambiando la Computer Vision

Per anni le CNN sono state lo standard.

Ora qualcosa sta cambiando.

Il punto di partenza

Le CNN (Convolutional Neural Networks) analizzano le immagini localmente.

➞ Guardano piccoli pezzi alla volta

➞ Costruiscono il significato strato dopo strato

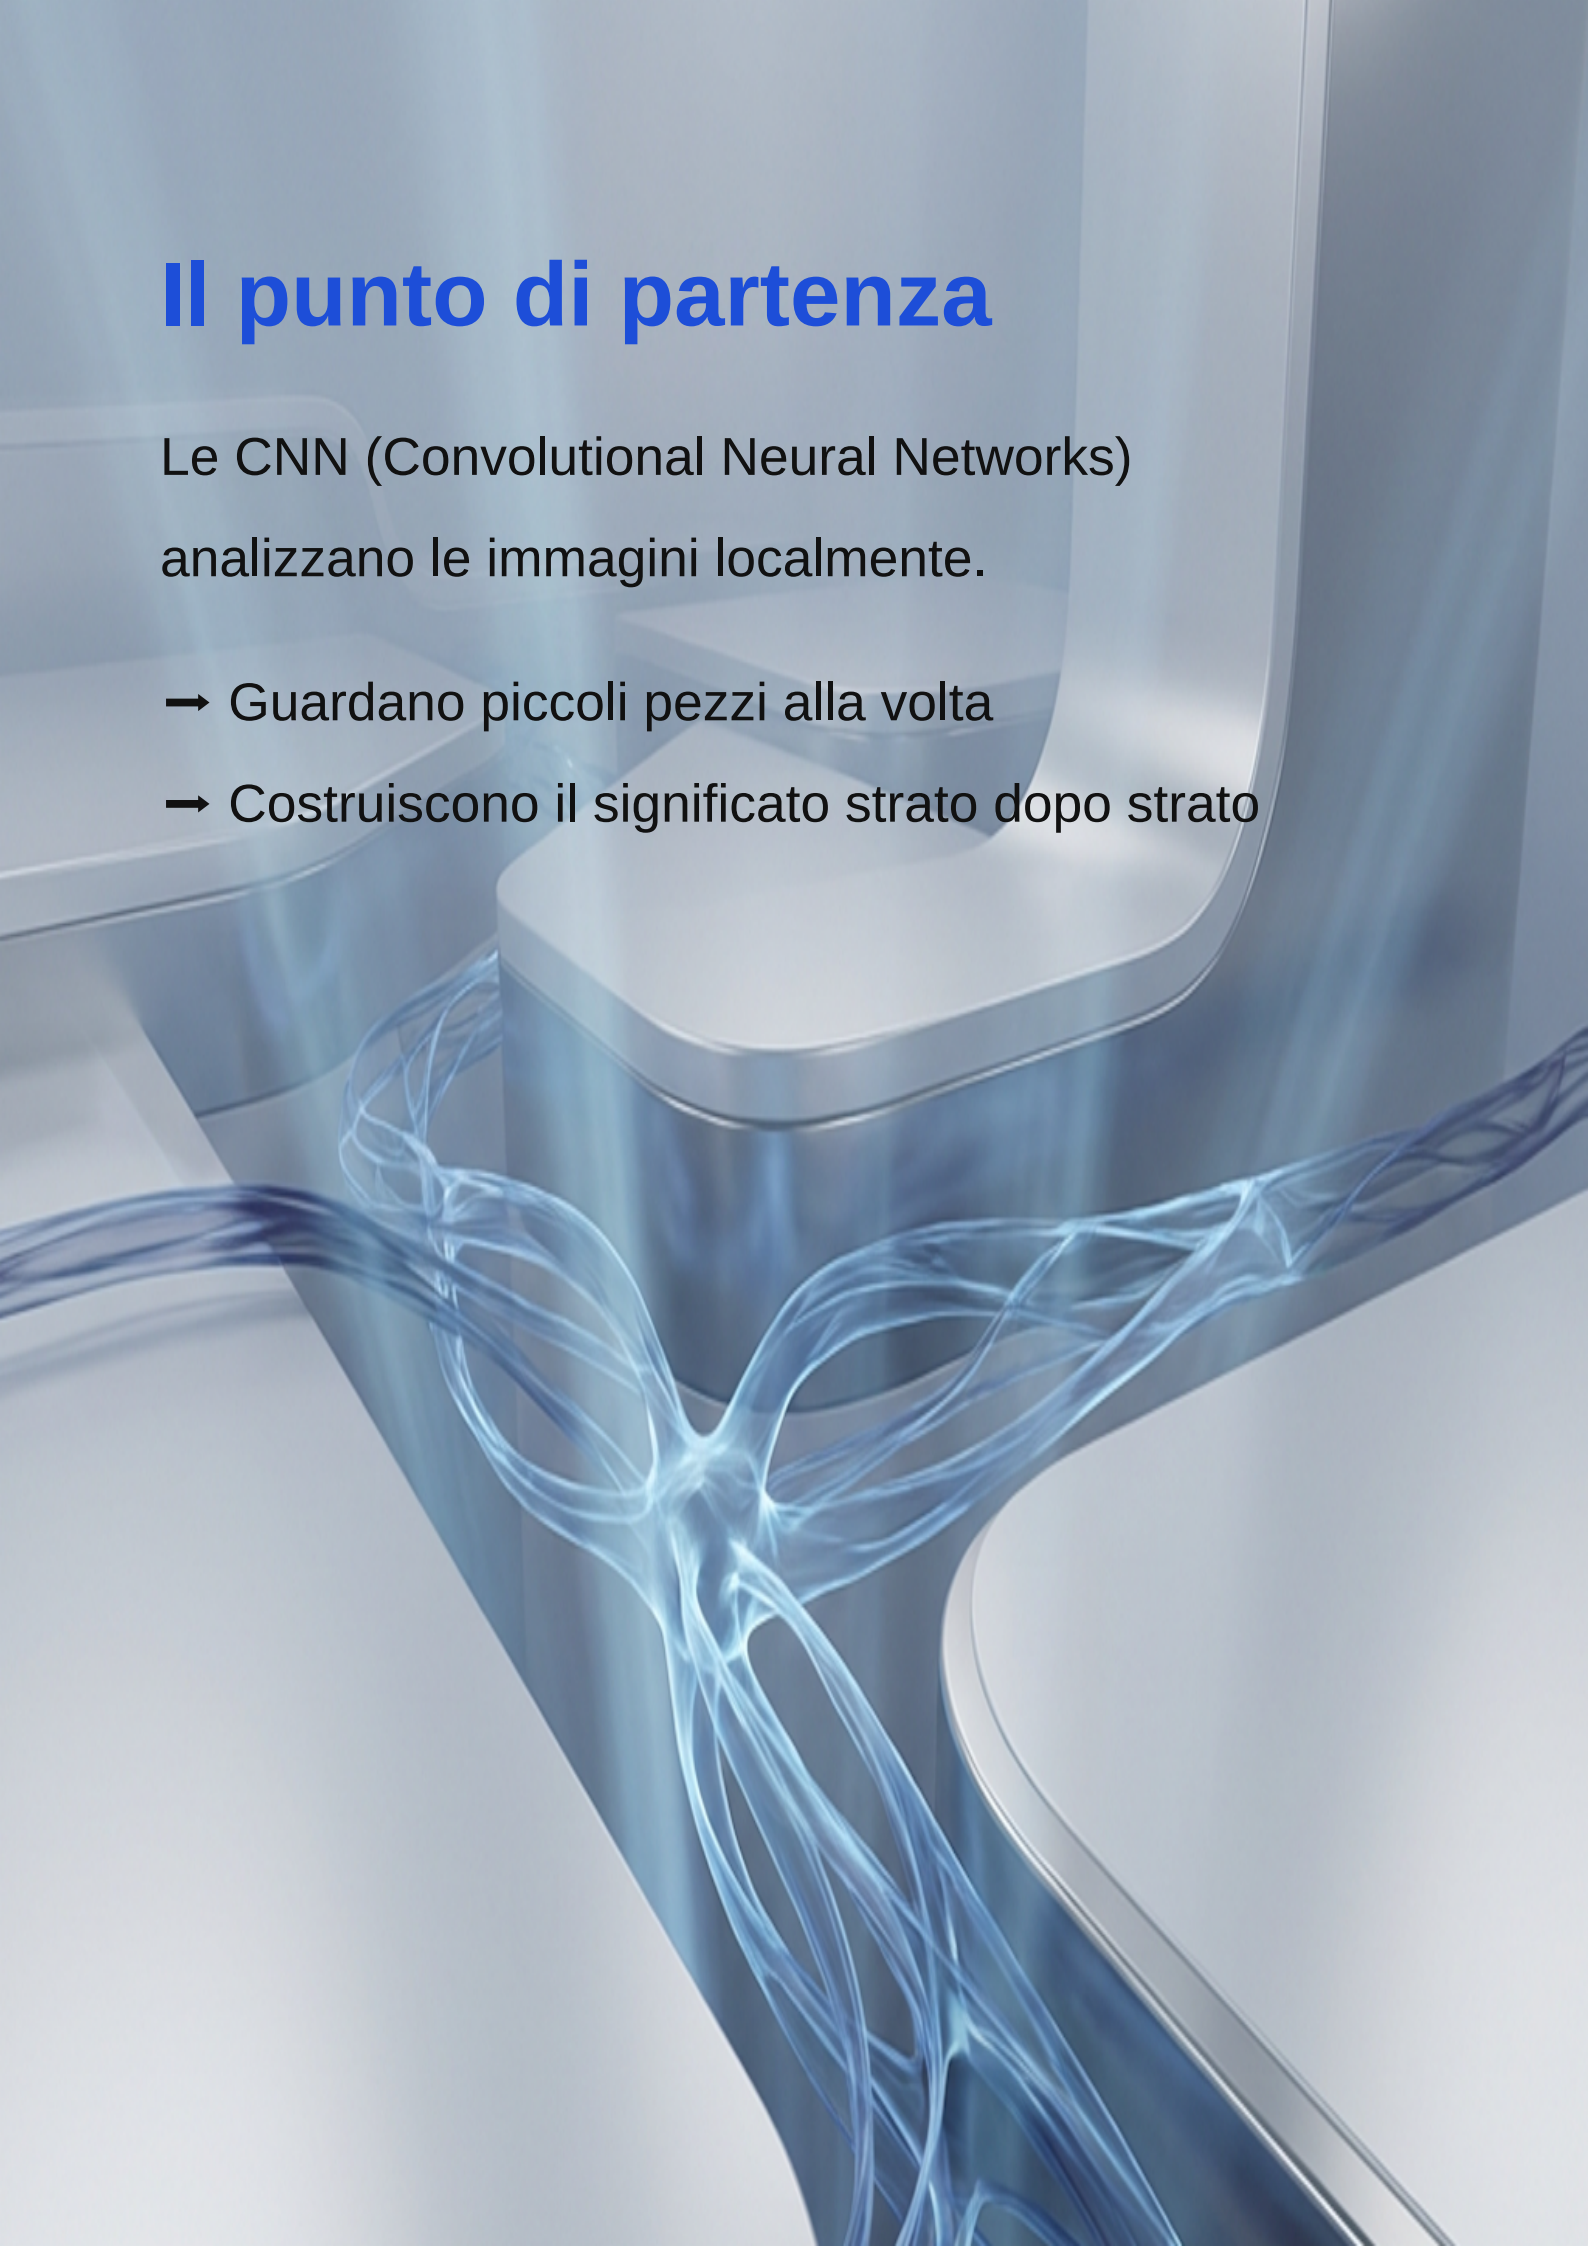

Il cambio di paradigma

I **Vision Transformer (ViT)** fanno qualcosa di diverso:

👉 Trattano l’immagine come una sequenza (proprio come fosse testo)

Come funziona

1. L’immagine → divisa in **patch** (es. 16x16)
2. Ogni **patch** → trasformata in **vettore**
3. Aggiunta informazione posizionale

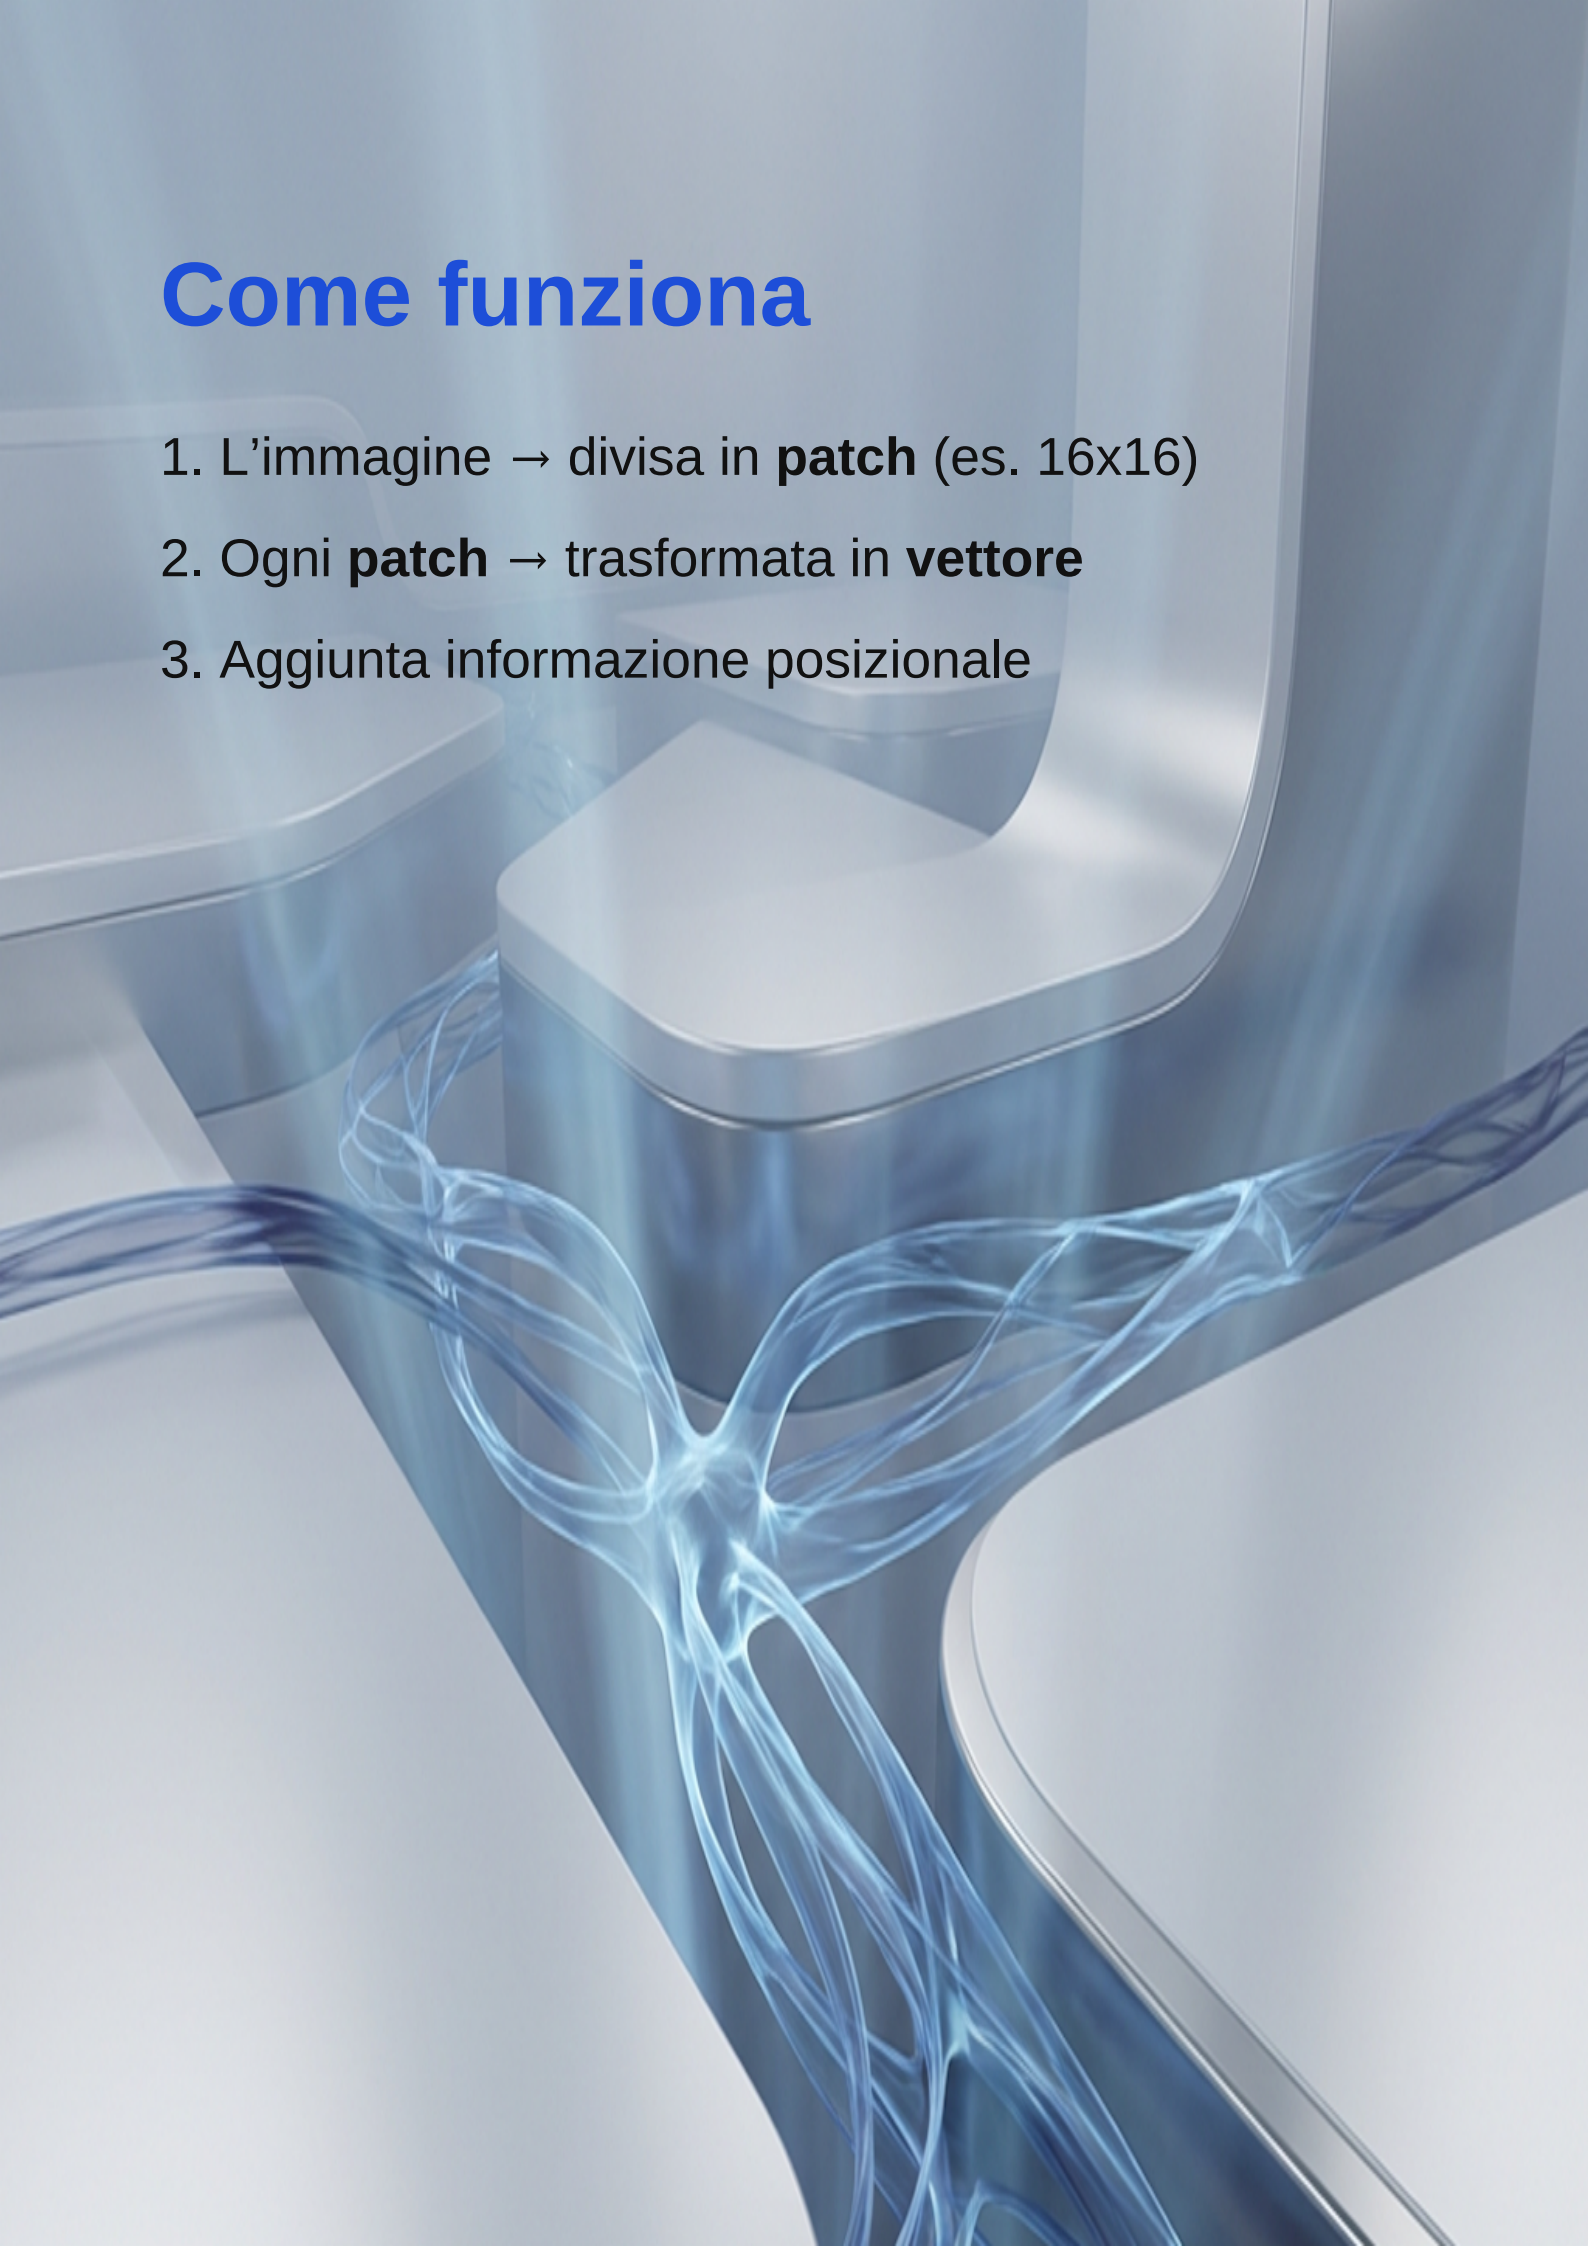

Il cuore del modello

La sequenza passa nei **Transformer Encoder**

✓ Self-attention

✓ MLP

✓ Residual + LayerNorm

Il vero vantaggio

💡 Ogni patch “vede” subito tutta l’immagine.

➞ Comprensione globale immediata

➞ Relazioni a lungo raggio

➞ Meno dipendenza da kernel fissi

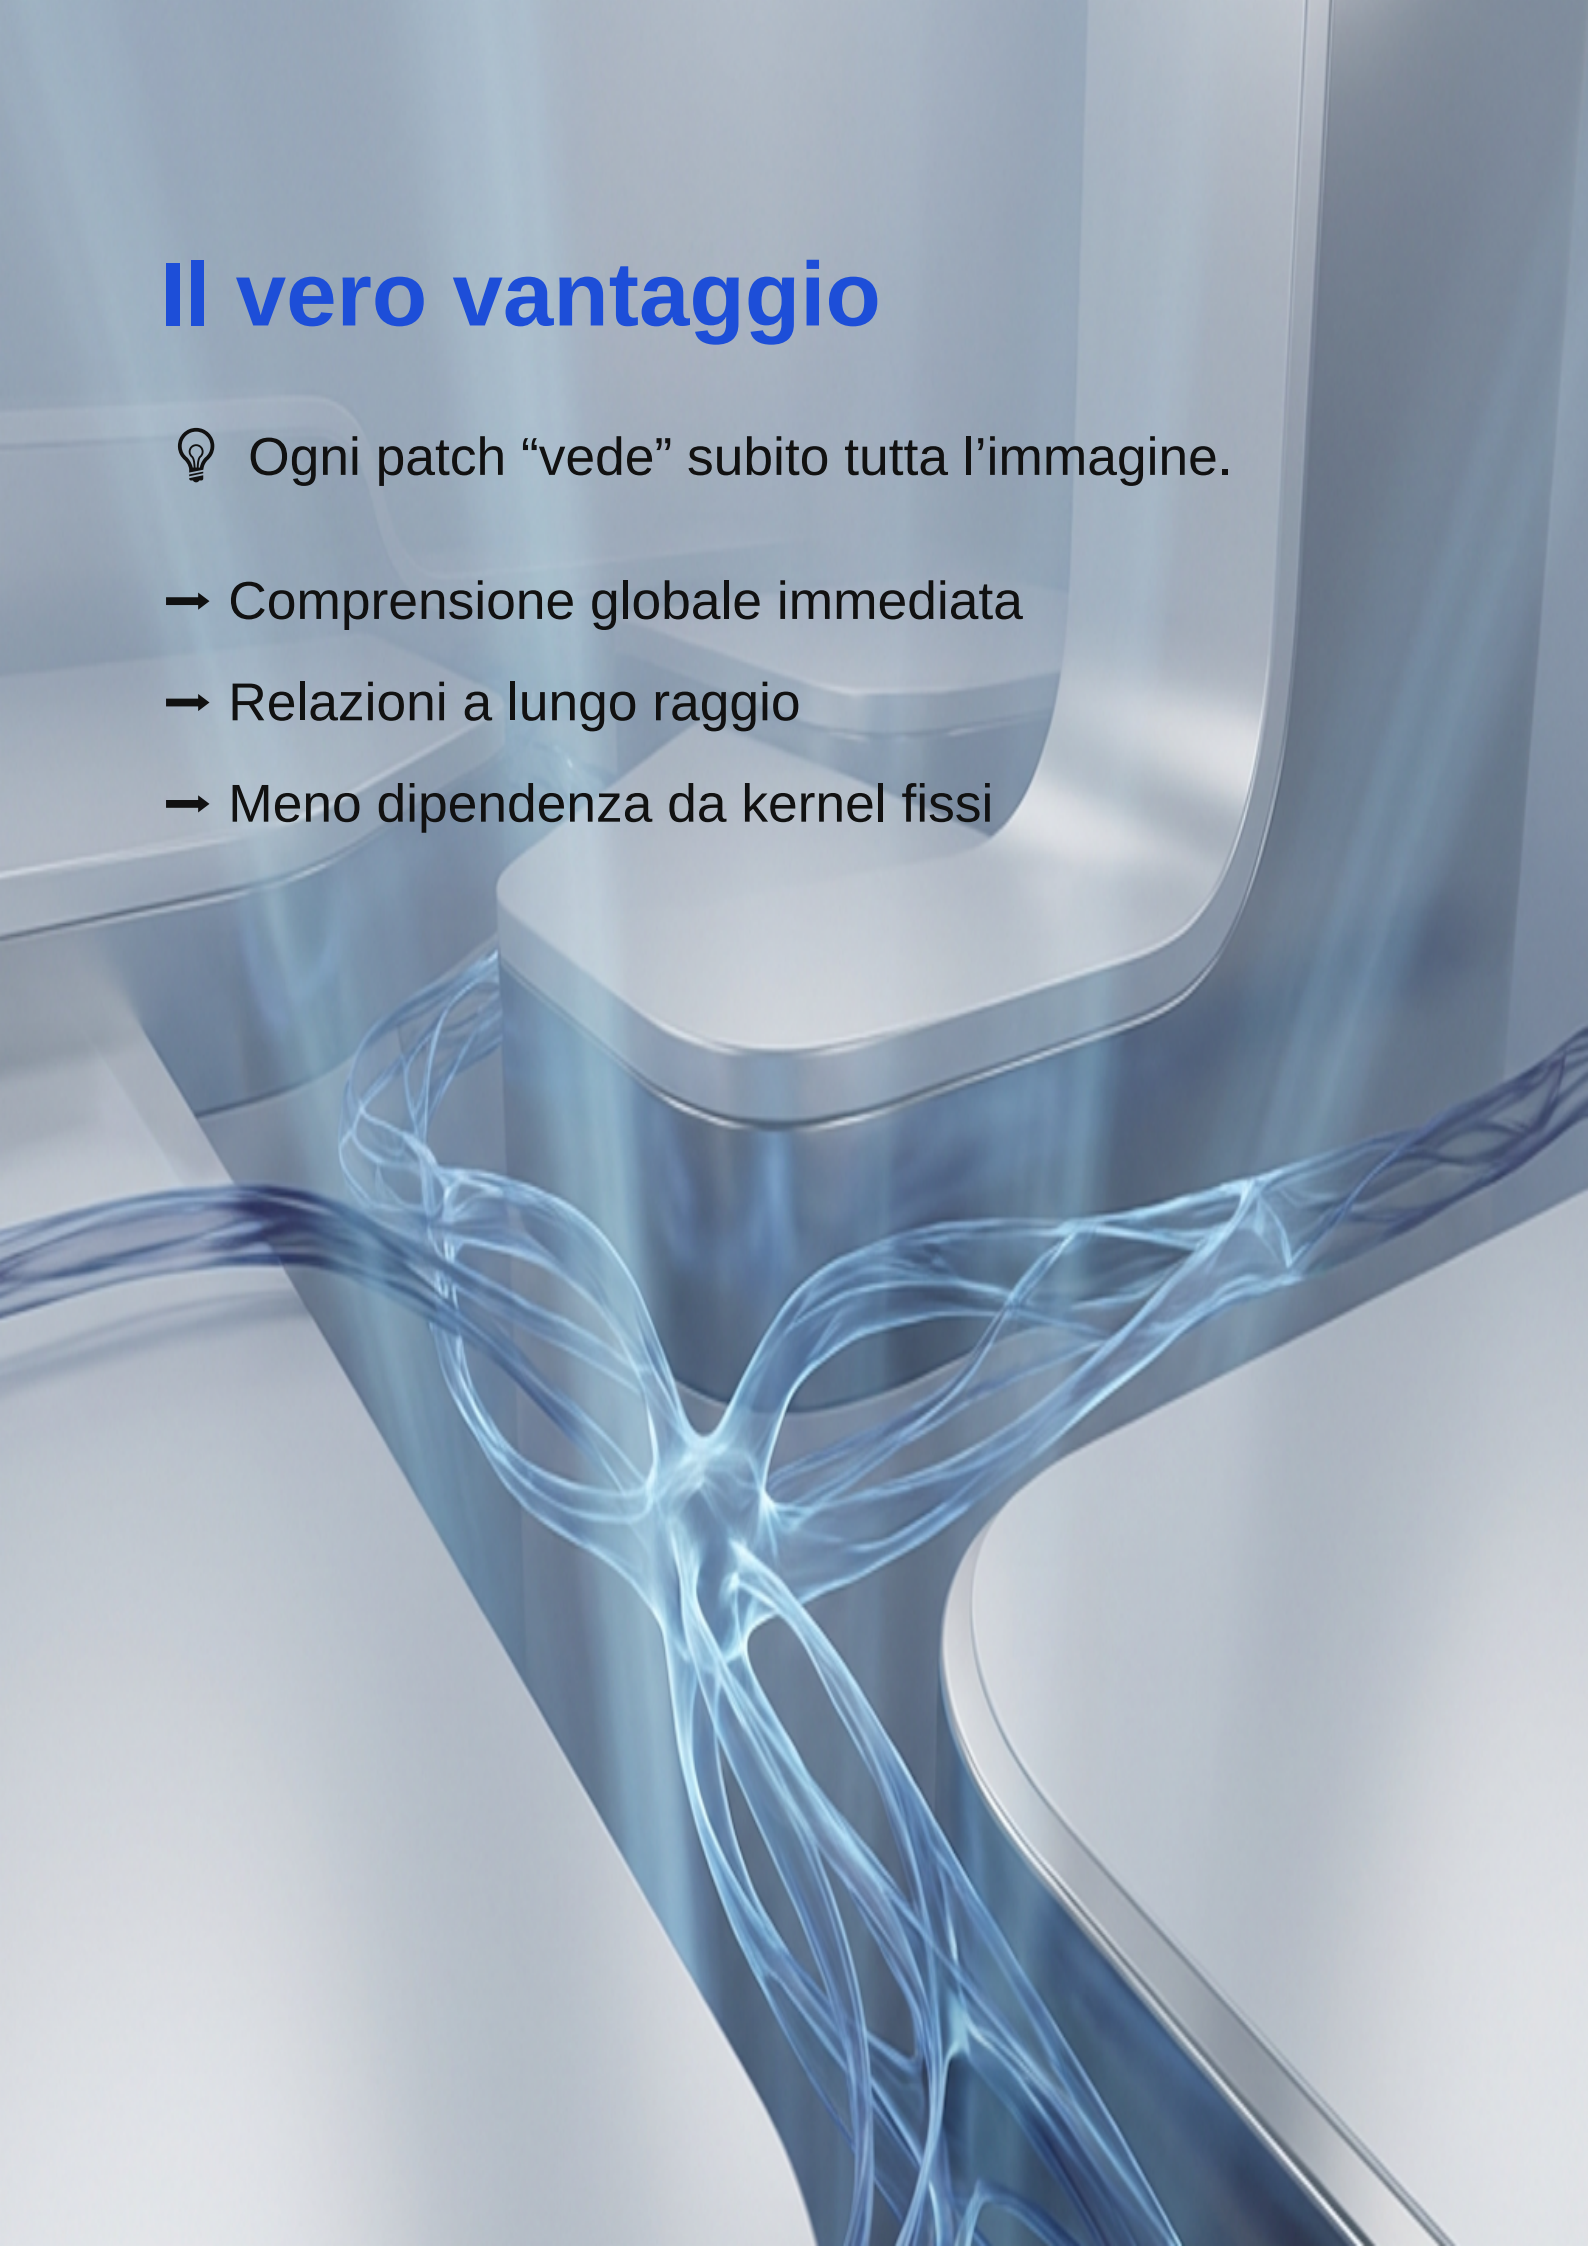

Caso concreto

🏥 Immagina una lastra medica:

👉 Individuare una massa

👉 Capire il contesto globale subito

Qui la differenza è reale.

I compromessi

⚖️ Non è tutto perfetto:

- ❌ Modelli molto grandi
- ❌ Servono tanti dati
- ❌ Costosi da addestrare da zero

Best practice

☑ Funzionano meglio così:

👉 Pre-trained

👉 Fine-tuning sul task specifico

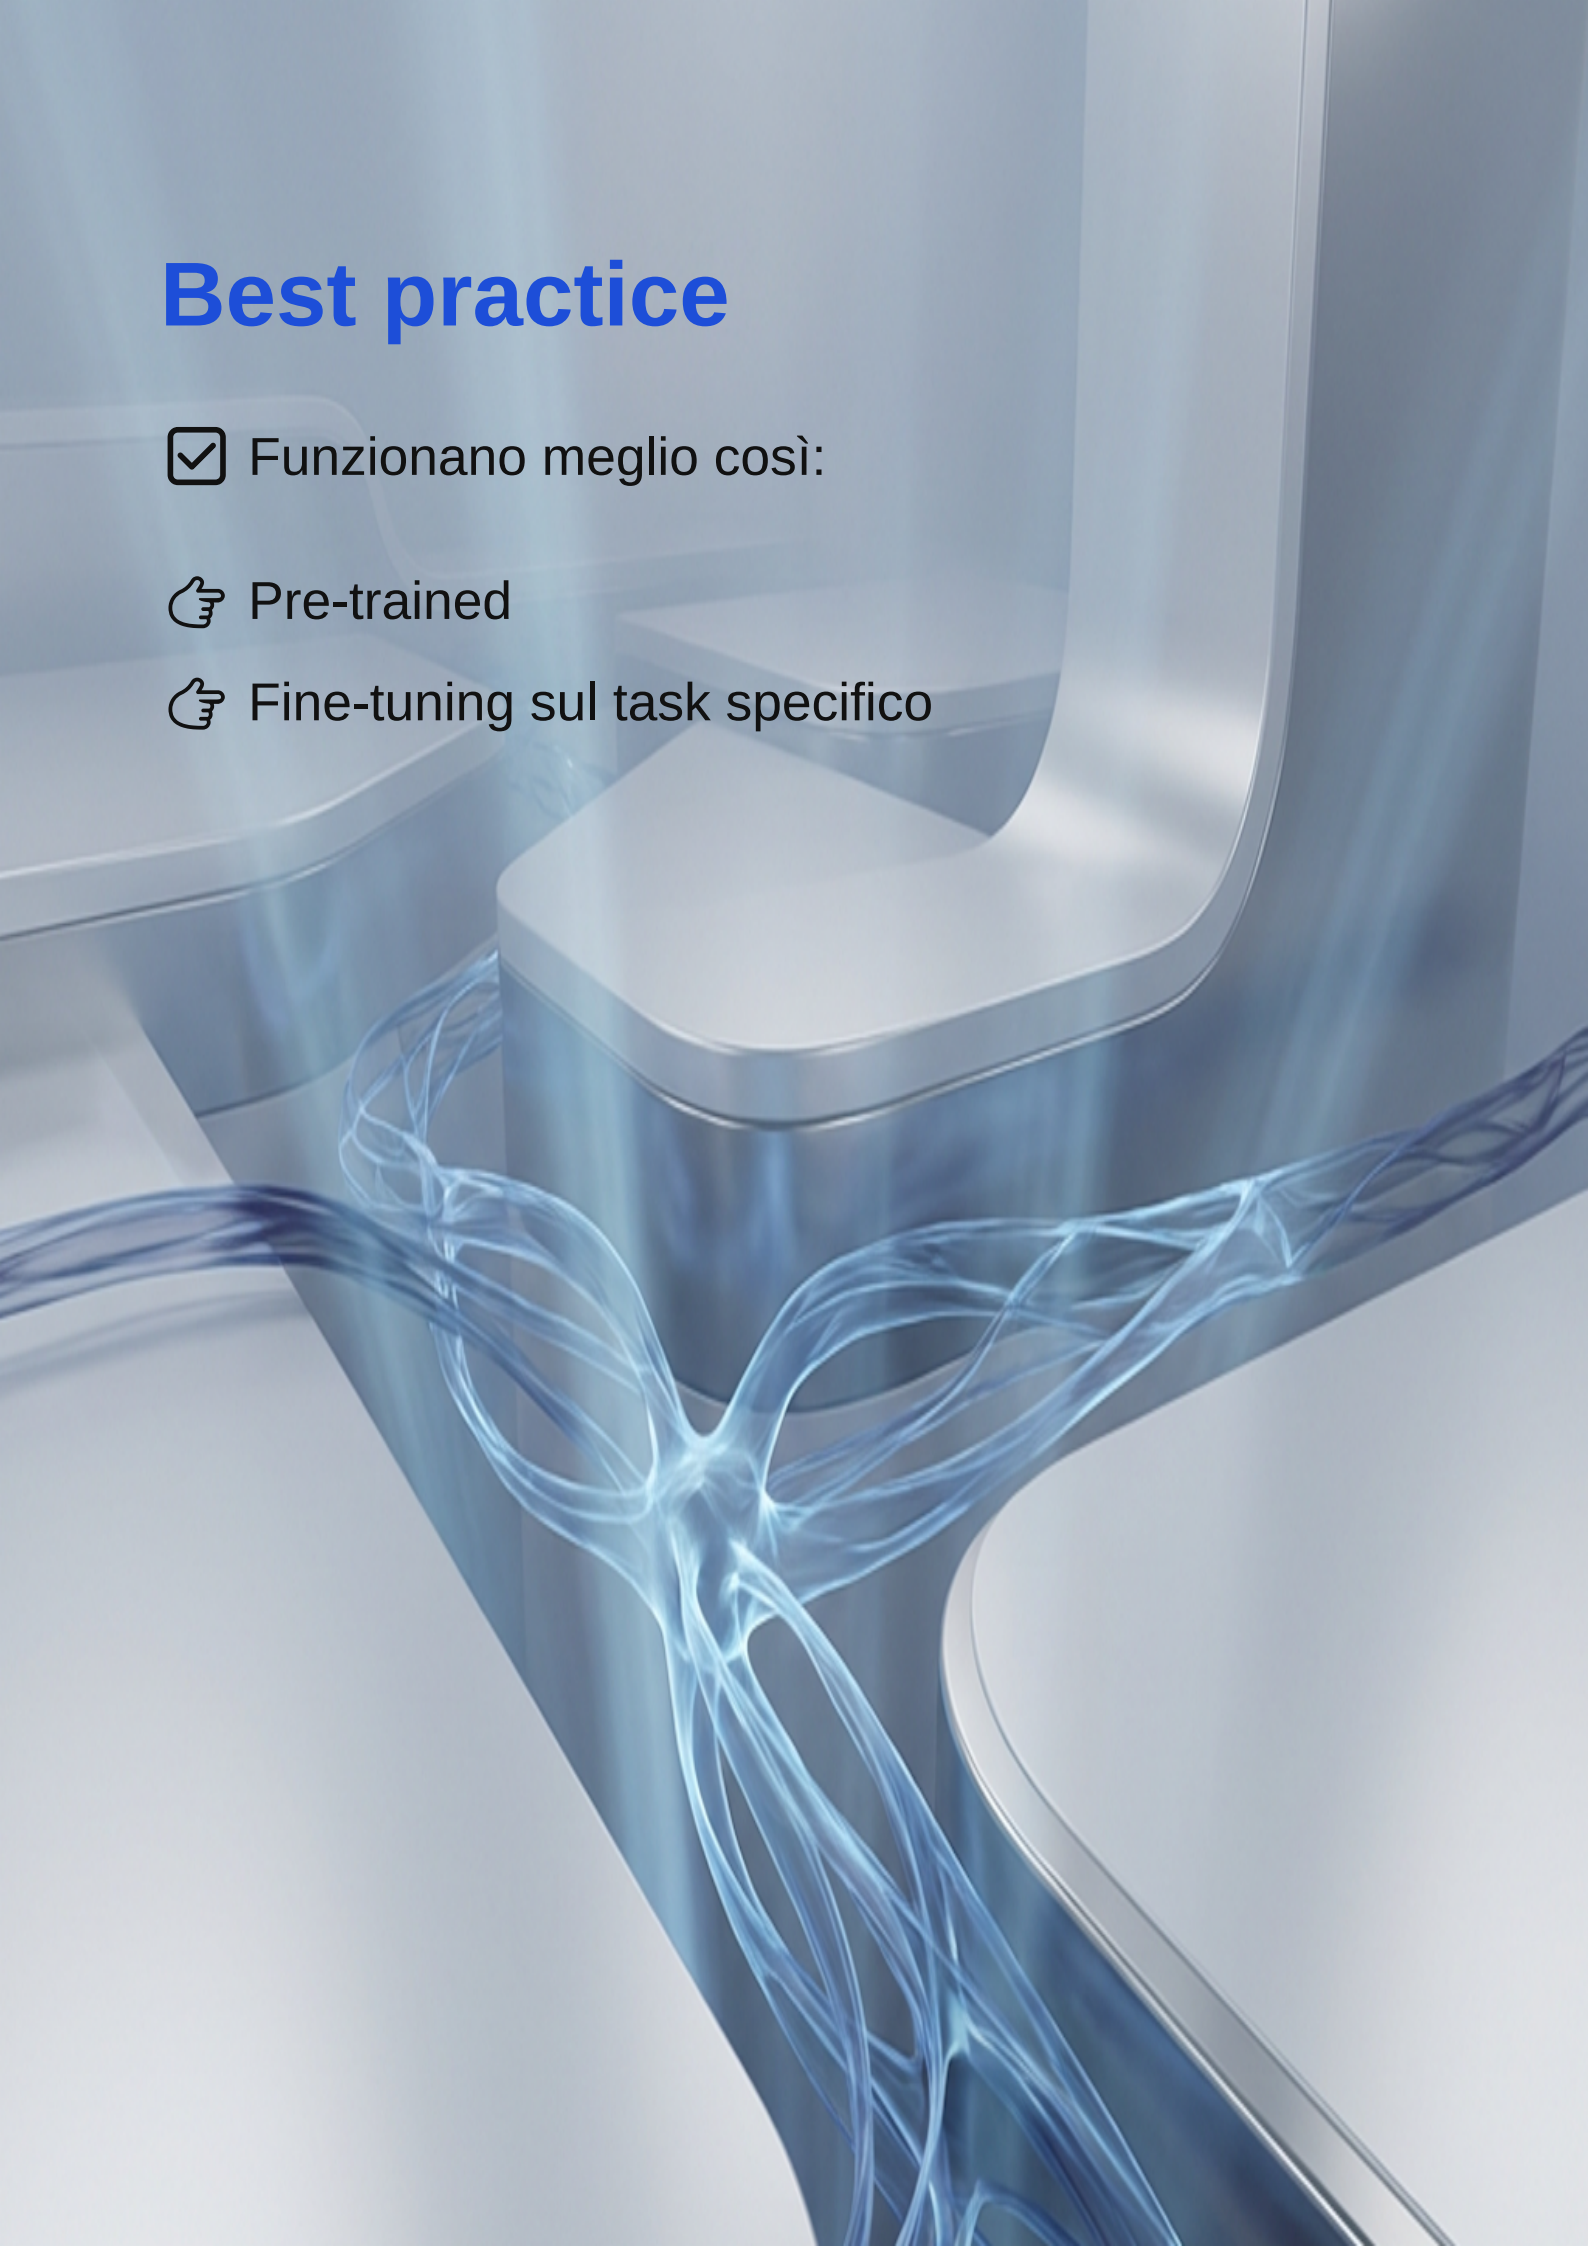

Conclusione

🚀 I ViT non sostituiscono le CNN.

Ma sono una svolta quando serve:

✓ Precisione

✓ Contesto globale

E in alcuni casi…

possono fare la differenza tra **errore** e una **diagnosi**.